Part1. KoNLPy 이해

[1] KoNLPy 사이트 둘러보기

https://konlpy-ko.readthedocs.io/ko/v0.4.3/

https://konlpy-ko.readthedocs.io/ko/v0.4.3/install/ (설치방법 나옴, 맥은 여기 확인)

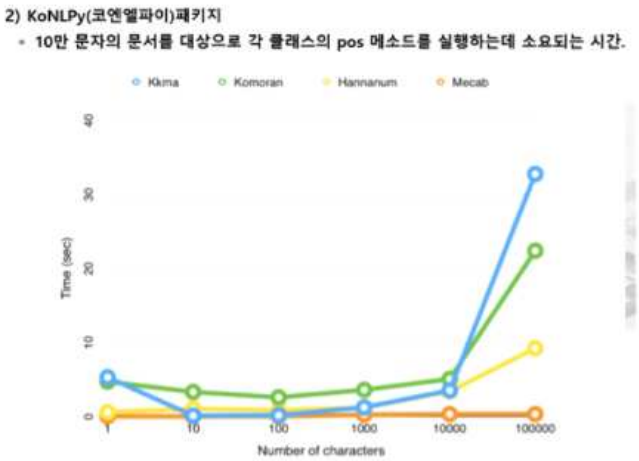

품사태그셋
https://happygrammer.github.io/nlp/postag-set/

Hannanum: 한나눔. KAIST Semantic Web Research Center 개발.

Kkma: 꼬꼬마. 서울대학교 IDS(Intelligent Data Systems) 연구실 개발.
http://kkma.snu.ac.kr/

Komoran: 코모란. Shineware에서 개발.
https://github.com/shin285/KOMORAN

Mecab: 메카브. 일본어용 형태소 분석기를 한국어를 사용할 수 있도록 수정.
https://bitbucket.org/eunjeon/mecab-ko

Open Korean Text: 오픈 소스 한국어 분석기. (구.트위터) 과거 트위터 형태소 분석기.
https://github.com/open-korean-text/open-korean-text

Part3. KoNLPy 실습

[0] Konlpy.pdf의 9~10페이지를 실습해봄

[1] 한글 형태소 분석할 파일 준비 (txt 파일 또는 크롤링한 자료도 가능함)

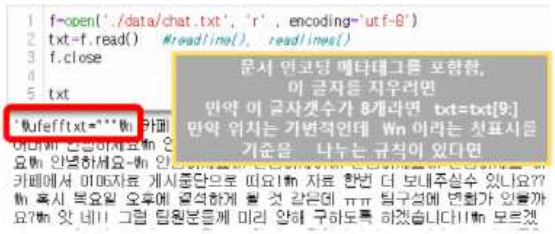

[2] 형태소분리

```
from konlpy.tag import Okt
f=open('c:/python_data/지식인_답변여행.txt', 'r' , encoding='utf-16')
txt=f.read()    #readline(),  readlines()
f.close

okt=Okt()
re=okt.nouns(txt)
re[:10]
```

[3] 글자수제한

```
### 글자의 길이
### 글자의 길이를 구하기 위해서는 각각 리스트에 있을때 하는게 편함

글자의길이조건준자료=[]
for i in range(len(re)):
    if len(re[i])>=2:
        글자의길이조건준자료.append(re[i])
글자의길이조건준자료[:10]
```

[4] 리스트자료 문자열로 변환

```
re1=' '.join(글자의길이조건준자료)
re1[:50]
```

[5] 워드클라우드 시각화

#stopword 추가 및 png이미지를 넣은 워드클라우드 시각화 가능함.

```
from wordcloud import WordCloud
import matplotlib.pyplot as plt
import numpy as np

wc = WordCloud('c:/malgun.ttf',
                background_color = "white",
               max_words = 2000)
               #stopwords = stopwords)
wc = wc.generate(re1)        # str자료만 가능, list자료는 안됨
plt.figure(figsize = (12, 12))
plt.imshow(wc, interpolation = "bilinear")
plt.axis("off")
plt.show()
```

[6] 단어집계 - from collections import Counter

* collections는 별도 모듈설치없이 사용가능함. 단어의 개수와 순위를 기억함
* most_common() 메서드를 이용하여서 단어수가 많은순으로 정렬하여서 return 받을수 있음.
* Counter함수 살펴보기

```
from collections import Counter
sample='hello world'
Counter(sample).most_common()
```

```
[('l', 3),
 ('o', 2),
 ('h', 1),
 ('e', 1),
 (' ', 1),
 ('w', 1),
 ('r', 1),
 ('d', 1)]
```

```
sample=['hello','hello','hi','eye']
Counter(sample).most_common()
```

```
[('hello', 2), ('hi', 1), ('eye', 1)]
```

```
from collections import Counter
sample=['hello world hello hi']
Counter(sample).most_common()
```

```
[('hello world hello hi', 1)]
```

```
sample='hello world hello hi'
sample1=sample.split(' ')
Counter(sample1).most_common()
```

```
[('hello', 2), ('world', 1), ('hi', 1)]
```

```
sample=[['hello','hello'],['hi','eye']]
Counter(sample).most_common()
```

```
TypeError                                 Traceback
Input In [5], in <cell line: 2>()
      1 sample=[['hello','hello'],['hi','eye']]
----> 2 Counter(sample).most_common()

TypeError: unhashable type: 'list'
```

```
sample=[['hello','hello'],['hi','eye']]

import numpy as np
print(np.shape(sample))
sample2=np.reshape(sample,4)
print(np.shape(sample2))

Counter(sample2).most_common()
```

```
(2, 2)
(4,)

[('hello', 2), ('hi', 1), ('eye', 1)]
```

*** 작업에 counter함수 적용하기**

re2=re1.split(' ') top=50 cnt = Counter(re2) top_=cnt.most_common(top) top_[:5]	[('', 137), ('제주', 71), ('시간', 67), ('코스', 48), ('추천', 45)]
dict=[] for i in range(top): dict.append({'word':top_[i][0],'freq':top_[i][1]}) dict[:5]	[{'word': '', 'freq': 137}, {'word': '제주', 'freq': 71}, {'word': '시간', 'freq': 67}, {'word': '코스', 'freq': 48},
import pandas as pd db = pd.DataFrame (dict)[:5] db	word freq 0 137 1 제주 71 2 시간 67 3 코스 48 4 추천 45
db[(db['word']!='제주') & (db['word']!='시간')]	word freq 0 137 3 코스 48 4 추천 45

[7] NLTK함수와 결합

```
from nltk import Text
from nltk.tokenize import RegexpTokenizer

import matplotlib.pyplot as plt
import numpy as np
%matplotlib inline
plt.rcParams["figure.figsize"] = (14,4) #차트 전체크기
plt.rc('font', family='Malgun Gothic')

top=30
retokenize = RegexpTokenizer("[\w]+")
text = Text(retokenize.tokenize(re1))     # 문자열을 읽어야함.정리다된 자료로 작업함.
```

```
plt.title('count top ' + str(top))
text.plot(30)
plt.show()
```

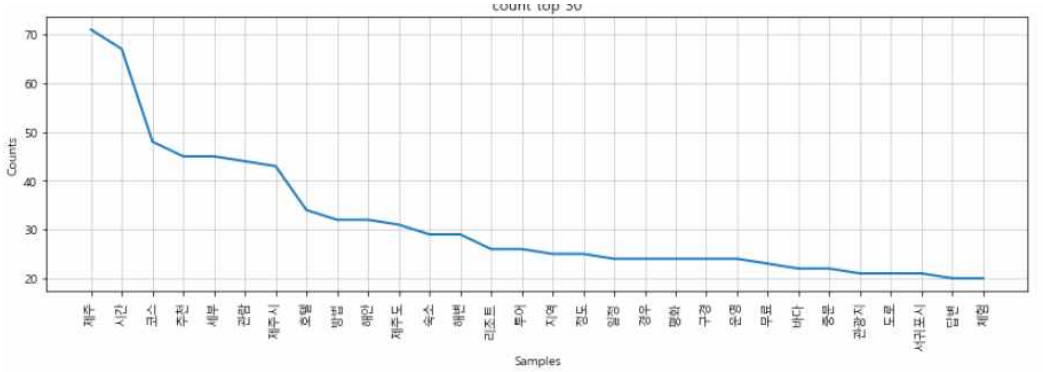

text.dispersion_plot(['자료','네'])